VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ
FAKULTA INFORMAČNÍCH TECHNOLOGIÍ

Dokumentace k projektu do IFJ/IAL

Implementace překladače jazyka IFJ18

Tým 106, varianta II

Členové týmu:

Lukáš Válek	–	xvalek15	25 %
Lukáš Piwowarský	–	xpiwow00	25 %
Adam Pankuch	–	xpanku00	25 %
Jindřích Šesták	–	xsesta05	25 %

Rozšíření: BASE, IFTHEN

5. prosince 2018

1 Úvod

Cílem projektu bylo vytvoření překladače pro jazyk IFJ18, který je podmnožinou jazyka Ruby. Vybrali jsme si II. variantu (tabulku s rozptýlenými položkami).

2 Etapy projektu

1. Návrh struktury programu (konečný automat (viz obrázek 1), LL gramatika (viz gramatika 1), LL-tabulka (viz tabulka 1), precedenční tabulka (viz tabulka 2))
2. Lexikální analýza
3. Prediktivní syntaktická analýza
4. Precedenční syntaktická analýza
5. Generování kódu
6. Testování
7. Tvorba dokumentace

3 Datové struktury

`token_t` – Struktura uchovávající informace o tokenech.
`stack_tkn_t` – Zásobník tokenů využívaný především v prediktivní analýze.
`stack_sa_t` – Zásobník realizovaný pomocí obousmerně vázaného seznamu využívaný v prec. analýze.
`stack_str_t` – Zásobník řetězců využívaný především při generování kódu.
`queue_t` – Fronta tokenů a řetězců využívaná v lexikální analýze.
`list_t` – Fronta řetězců realizována pomocí jednosměrně vázaného seznamu.
`symtable_t` – Tabulka s rozptýlenými položkami.
`dynamic_arr_t` – Dynamické pole parametrů funkce.
`dynamic_str_t` – Dynamický řetězec využívaný v lexikální analýze k ukládání lexémů.

4 Lexikální analýza

Lexikální analyzátor (dále jen LA) představoval první část projektu, kterou bylo nutno implementovat. Zavedli jsme obousměrnou komunikaci mezi LA a syntaktickým analyzátorem (dále jen SA), kdy SA může číst token, ale také vrátit token zpět do LA. Při dalším volání LA není token čten ze standartního vstupu, ale z fronty, ve které jsou uchovávány dříve vrácené tokeny. Toto je realizováno pomocí datové struktur `queue_t`. Dále lexikální analyzátor zajišťuje ignorování komentářů. Produktem LA je datová struktura `token_t`, se kterou se pak dále pracuje v ostatních částech překladače.

5 Syntaktický analýza

5.1 Prediktivní analýza

Rozhodli jsme se použít prediktivní analýzu (dále jen PA), protože nám přišla sofistikovanější a také jako větší výzva na implementaci. Pravidla LL gramatiky společně s LL-tabulkou jsou umístěny přímo v kódě překladače, a to přesně v takové podobě, v jaké jsou uvedené v příloze. Poslední sloupec v LL-tabulce pojmenovaný "expr"nekoresponduje s žádným terminálem používaným v LL gramatice, ale souhrně reprezentuje všechny tokeny, kterými může precedenční analýza výrazů začínat (v případě výrazu, který následně není přiřazený žádné proměnné). V PA používáme tyto datové struktury:

`stack_str_t` – Zásobník ukládající generovaný kód při if-statement, while-loop a definicích funkcí.
`stack_tkn_t` – Zásobník nutný pro implementaci algoritmu prediktivní analýzy.

5.2 Precedenční analýza

Výrazy jsou jsou zpracovávány metodou precedenční syntaktické analýzy pomocí algoritmu známého z přednášek. Analyzátor komunikuje se třemi hlavními moduly: scannerem, prediktivním analyzátorem a generátorem cílového kódu. Při implementaci jsou použity tyto pomocné datové struktury:

`stack_sa_t` – Zásobník uchovávající příchozí tokeny (terminály) ze scanneru, včetně následných neterminálů, které vzniknou při analyzování výrazu.
`stack_tkn_t`– Zásobník uchovávající parametry, se kterými je volána funkce v zdrojovém kódu.

6 Sémantická analýza

Sémantická analýza probíhá ve třech modulech, a to v: predektivním analyzátoru, precedenčním analyzátoru a v generátoru cílového kódu (pro vestavěné funkce a výrazy).

Prediktivní analyzátor společně s precedenčním analyzátorem je odpovědný za ověřování správného počtu parametrů při volání funkcí, za ověřování redefinice funkcí a kolize jmen proměnných a funkcí.

Generátor vnitřního kódu kontroluje datové typy operandů, pokud je to možné. V případě, že alespoň jeden operand je proměnná, dochází k sémantické kontrole za běhu. Dále zajišťuje běhovou kontrolu dělení nulou.

7 Implementace tabulky symbolů

Tabulka symbolů je implementována jako tabulka s rozptýlenými položkami s explicitně zřetězenými synonymy. Synonyma jsou vkládána do jednosměrně vázaného lineárního seznamu, přičemž nové položky jsou vkládány na jeho začátek. V programu se pracuje se dvěma druhy tabulek symbolů a to s tabulkou pro funkce a tabulkou pro proměnné. Tabulek proměnných může být několik, protože každá odpovídá za proměnné v jednom bloku kódu. Tabulka funkcí je pouze jedna a slouží k zaznamenávání informací o funkcích, které jsou přístupné z kterékoliv úrovně kódu.

8 Generování kódu

Pro potřeby tohoto projektu jsme zvolili přímé generování tří adresného kódu, protože jiné metody neposkytovaly žádnou výhodu jen časové zdržení. Instrukce generujeme do abstraktního datového typu `list_t`, protože je potřeba zamezit vícenásobné deklaraci v cyklech. Pokud se analýza nachazí ve while-loop nebo if-statement, tak budou veškeré instrukce deklarace proměnných vytisknuty před začátkem while-loop respektive if-statement.

Generování kódu probíhá v těchto modulech: prediktivní analyzátor a precedenční analyzátor. Prediktivní analyzátor generuje cílový kód pro definice funkcí, if-statement, while-loop a definování proměnných. Precedenční analyzátor generuje cílový kód pro volání funkcí, volání vestavěných funkcí a výrazy.

8.1 Generování cílového kódu pro výrazy

V rámci generování instrukcí pro výrazy se musela provádět sémantická analýza. Tu jsem provedli použitím instrukcí pro zjištění typu proměnných, jejich přetypováním a následných skoků. Při generování kódu jsme se rozhodli pro lehkou optimalizaci. Ta spočívá v tom, že na základě datových typů operandů, získaných z precedenční analýzy, se vygenerují jen ty nejnutnější instrukce. Tím se omezí množství skoků a testů ve výsledném programu.

9 Rozdělení práce

Lukáš Válek

- Tabulka symbolů
- Implementace stacku pro řetězce
- Generování cílového kódu pro výrazy
- Generování cílového kódu pro vestavěné funkce
- Implementace dynamického pole parametrů

Lukáš Piwowarski

- Návrh a implementace precedenční analýzy
- Implementace stacku pro tokeny
- Generování cílového kódu pro volání funkcí
- Implementace stacku pro precedenční analýzu

Adam Pankuch

- Návrh a implementace prediktivní analýzy
- Implementace datové struktury list, queue
- Generování cílového kódu pro if-statement, while-loop, definice funkcí, definice proměnných
- Implementace testovacího skriptu

Jindřich Šesták

- Návrh a implementace lexikálního analyzátoru
- Generování cílového kódu pro if-statement, while-loop
- Generování vestavěných funkcí
- Implementace dynamického řetězce

Dále se každý podílel na tvorbě dokumentace a tvorbě testovacích zdrojových kódů.

10 Rozšíření

10.1 BASE

Toto rozšíření jsme řešili pouze malou úpravou v LA.

10.2 IFTHEN

Už v návrhu LL gramatiky jsme počítali s tímto rozšířením, proto nebyly potřebné pozdější úpravy.

11 Komunikace v týmu

Jako hlavní komunikační kanál sloužil Messenger, popř. Discord (videohovory). Dále probíhaly pravidelné schůzky, na kterých jsme prodiskutovávali udělenou práci a rozdělovali jsme novou.

Jako verzovací systém jsme použili Git hostovaný na službě Github.

12 Shrnutí

Projekt byl pro nás zcela novou zkušeností. Nikdo z nás nikdy nepracoval na větším týmovém projektu, proto nám proces tvoření překladače přinesl spoustu nových znalostí, nejen z oblasti formálních jazyků, programování v jazyce C, návrhu komplexnějšího programu, ale také z oblasti týmové práce a uskalými s ní spojenými, jako je například komunikace. Určitě byl pro nás projekt přínosem.

	if	**else**	**elseif**	**end**	**while**	**def**	**EOL**	**EOF**	**=**	**(**	**)**	**,**	**ID**	**FUNC**	**"expr"**
[st-list]	1	0	0	0	1	1	2	3	0	1	0	0	1	1	1
[EOL-EOF]	0	0	0	0	0	0	4	5	0	0	0	0	0	0	0
[stat]	7	0	0	0	7	6	0	0	0	7	0	0	7	7	7
[command]	9	0	0	0	8	0	0	0	0	0	0	0	10	0	0
[func-assign-expr]	0	0	0	0	0	0	0	0	11	0	0	0	0	0	0
[end-list]	12	0	0	14	12	0	13	0	0	12	0	0	12	12	12
[if-list]	15	18	17	19	15	0	16	0	0	15	0	0	15	15	15
[id-func]	0	0	0	0	0	0	0	0	0	0	0	0	20	21	0
[params-gen]	0	0	0	0	0	0	0	0	0	22	0	0	0	0	0
[p-brackets]	0	0	0	0	0	0	0	0	0	0	24	0	23	0	0
[p-brackets-cont]	0	0	0	0	0	0	0	0	0	0	26	25	0	0	0

Tabulka 1: LL tabulka

Gramatika 1: LL GRAMATIKA

1: [st-list] → [stat] [EOL-EOF]
2: [st-list] → EOL [st-list]
3: [st-list] → ε
4: [EOL-EOF] → EOL [st-list]
5: [EOL-EOF] → ε
6: [stat] → def [id-func] [params-gen] [end-list]
7: [stat] → [command]
8: [command] → while do EOL [end-list]
9: [command] → if then EOL [if-list]
10: [command] → ID [func-assign-expr]
11: [func-assign-expr] → =
12: [end-list] → [command] EOL [end-list]
13: [end-list] → EOL [end-list]
14: [end-list] → end
15: [if-list] → [command] EOL [if-list]
16: [if-list] → EOL [if-list]
17: [if-list] → elif then EOL [if-list]
18: [if-list] → else EOL [end-list]
19: [if-list] → end
20: [id-func] → ID
21: [id-func] → FUNC
22: [params-gen] → ([p-brackets]
23: [p-brackets] → ID [p-brackets-cont]
24: [p-brackets] →) EOL
25: [p-brackets-cont] → , ID [p-brackets-cont]
26: [p-brackets-cont] →) EOL

OP	+	*	(	)	i	-	/	rel	f	,	$
+	>	<	<	>	<	>	<	>	X	>	>
*	>	>	<	>	<	>	>	>	X	>	>
(	<	<	<	=	<	<	<	<	X	=	X
)	>	>	X	>	X	>	>	>	X	>	>
i	>	>	X	>	X	>	>	>	X	>	>
-	>	<	<	>	<	>	<	>	X	>	>
/	>	>	<	>	<	>	>	>	X	>	>
rel	<	<	<	>	<	<	<	<	X	>	>
f	X	X	=	X	<	X	X	X	X	<	>
,	X	X	X	=	<	X	X	X	X	=	>
$	<	<	<	X	<	<	<	<	<	X	X

Tabulka 2: Precedenční tabulka

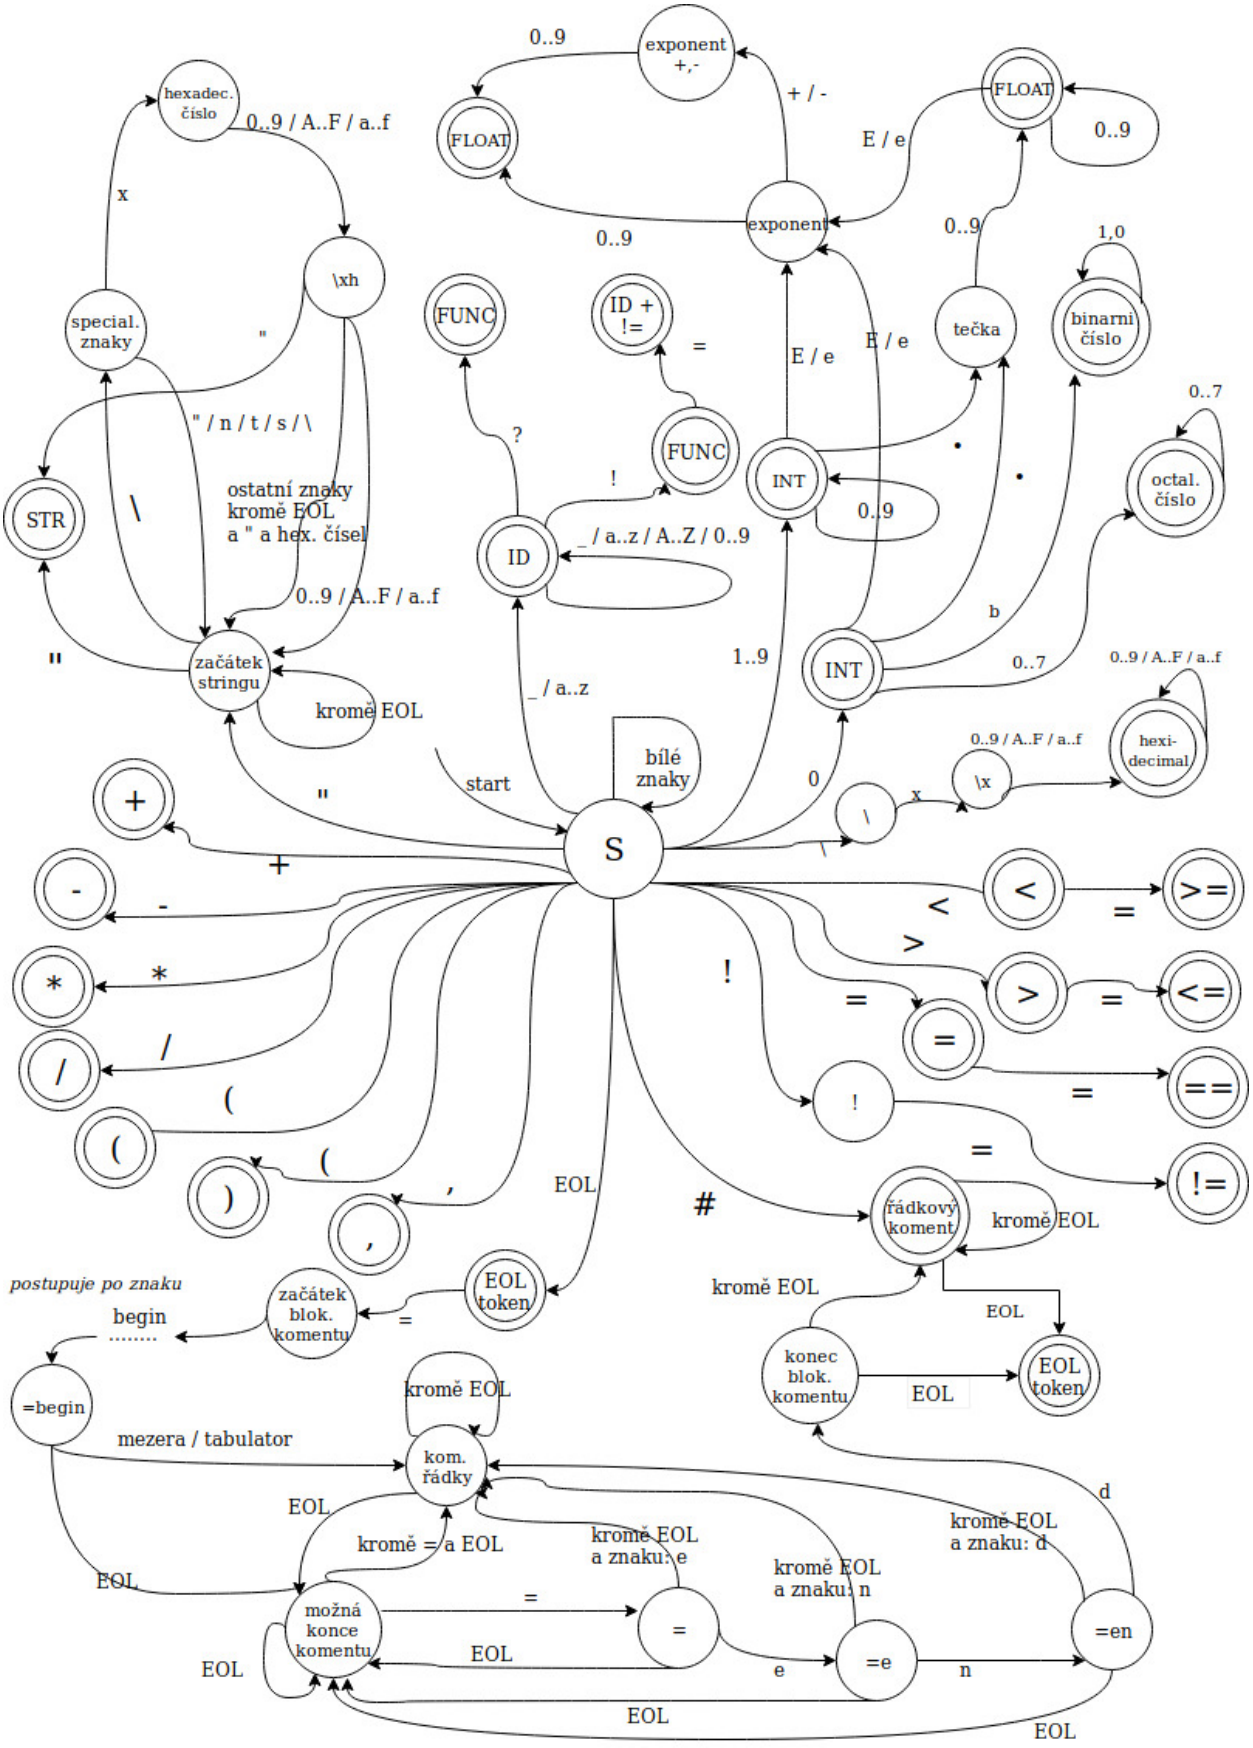

Obrázek 1: Konečný automat